

IRONMAN: un Jarvis local en CPU — cuantización, KV cache, RAG y herramientas MCP

Guillermo Paredes — Applied Machine Learning: Local LLM Systems

Junio 2026

1. Abstract

Presentamos IRONMAN, un asistente personal tipo “Jarvis” que corre íntegramente en la CPU de un portátil con menos de 16 GB de RAM, sin ningún LLM en la nube. El sistema combina un modelo llama3.2 de 3B parámetros servido por Ollama, un pipeline RAG local (nomic-embed-text + sqlite-vec) sobre ~202 páginas de documentación técnica, y seis herramientas expuestas mediante un servidor propio del Model Context Protocol (MCP), incluyendo correo IMAP/SMTP y control del PC. La interfaz principal es de texto (asistente/jarvis.py). Medimos el efecto de tres niveles de cuantización (Q8_0, Q4_K_M, Q3_K_M) sobre tamaño, RAM y velocidad; verificamos el crecimiento aproximadamente lineal del KV cache entre 512 y 16 384 tokens de contexto y el ahorro de cuantizarlo a Q8; y evaluamos el sistema completo con un test set reproducible de 21 prompts en cinco categorías. El hallazgo principal: Q4_K_M es el mejor compromiso —~1.7× más tokens/s que Q8_0 con idéntica calidad media (2.4/3)—, mientras Q3_K_M la degrada a 2.0 al fallar la aritmética; y el KV cache medido crece ~117 KB/token, casi exactamente los 112 KB/token teóricos, confirmando su crecimiento lineal con el contexto.

2. Arquitectura del sistema




Figure 1: Arquitectura del sistema

Figura 1. Arquitectura general. El usuario interactúa por texto con jarvis.py, que orquesta la inferencia local (Ollama), la llamada a herramientas (MCP) y la recuperación (RAG). Ningún componente de inferencia sale a la nube.

La interfaz del núcleo es de texto (asistente/jarvis.py), la misma que usa la evaluación automática de la Parte E. Todas las llamadas de inferencia fijan num_gpu: 0: el equipo tiene una RTX 4060 que se deshabilita explícitamente para cumplir la restricción de hardware del enunciado.

El servidor MCP propio (asistente/mcp_server.py) expone seis herramientas por stdio: `fetch_recent_emails` y `send_email` (Gmail IMAP/SMTP), `open_app`, `open_website` y `web_search` (control del PC y búsqueda), y `search_docs` (puente al RAG sobre top-4 de 1134 chunks del corpus de docs de Ollama y llama.cpp, ~202 págs).




Figure 2: Pipeline RAG

Figura 2. Pipeline RAG. El indexado (offline, parte `c_rag.py ingest`) trocea el corpus, lo incrusta con `nomic-embed-text` y lo guarda en `sqlite-vec`. En consulta (online, parte `c_rag.py`) la pregunta se incrusta con el mismo modelo, se recuperan los top-K fragmentos por similitud coseno y se inyectan en el prompt.




Figure 3: Llamada a herramienta vía MCP

Figura 3. Secuencia de una llamada a herramienta. El LLM decide emitir un `tool_call`, el cliente MCP de `jarvis.py` ejecuta la herramienta en el servidor, y el resultado vuelve al modelo como contexto para la respuesta final. El `fallback_tool_call_in_text` captura los casos en que llama3.2 emite la llamada como JSON dentro del texto.

3. Metodología

Hardware. ASUS ROG Strix G614JV: Intel i7-13650HX (14 núcleos / 20 hilos), 15.6 GB RAM, Windows 11. GPU dedicada deshabilitada por software (`num_gpu: 0` en cada petición; verificado observando 0 MB de VRAM en uso durante los runs).

Modelos. llama3.2 3B instruct en Q8_0 (3.4 GB), Q4_K_M (2.0 GB) y Q3_K_M (1.7 GB), servidos por Ollama 0.30.6. Embeddings: `nomic-embed-text` (274 MB, 768 dims). Generación determinista: `temperature=0`, `seed=42`.

Medición. tokens/s tomados de los contadores del propio API de Ollama (`eval_count/eval_duration` para generación; `prompt_eval_*` para prefill). RAM pico: muestreo cada 200 ms del working-set de todos los procesos `ollama*` durante la inferencia (`psutil`). Velocidad: completación fija de 200 tokens, media de 3 repeticiones. Calidad: 5 prompts estandarizados (matemáticas, código, resumen, memoria factual, razonamiento) puntuados 0-3 con la rúbrica escrita de `rubrica.md`; el prompt de código se valida además ejecutándolo sobre 5 casos de prueba.

Corpus RAG. Documentación oficial de Ollama (repo GitHub + web docs.ollama.com) y de llama.cpp: 115 ficheros markdown, ~90 800 palabras (~202 páginas). Justificación: (a) es exactamente el dominio del que el asistente debe ser experto; (b) contiene hechos puntuales y verificables (variables de entorno, flags, formatos) que un modelo de 3B **no** sabe de memoria, lo que hace medible el efecto del RAG; (c) es público y reconstruible con un script (setup.ps1). Chunking: ~1000 caracteres por párrafos con solape de 150; almacenamiento en sqlite-vec.

Test set. 21 prompts en 5 categorías (chat puro, RAG, herramienta, multi-paso, adversarial), cada uno con un tipo de resultado esperado declarado (tools requeridas/prohibidas, palabras clave). Runner automático (evaluacion/parte_e_evaluacion.py) con veredicto success/partial/fail, latencia y tokens por test. Las herramientas con efectos secundarios se ejecutan en seco para poder repetir la evaluación sin enviar correos reales.

4. Resultados

4.1 Parte A — Cuantización

Quant	Tamaño (GB)	RAM pico (MB)	Prefill (tok/s)	Generación (tok/s)	Calidad (0-3)
Q8_0	3.19	5558	230.4	11.23	2.4
Q4_K_M	1.88	2545	524.4	19.24	2.4
Q3_K_M	1.57	1985	581.2	22.52	2.0




Figure 4: Tamaño vs velocidad vs calidad

Bajar de Q8_0 a Q4_K_M reduce el peso a la mitad (3.19→1.88 GB) y la RAM pico a menos de la mitad (5.6→2.5 GB), y a la vez **acelera** la generación 1.7× (11.2→19.2 tok/s) y el prefill 2.3× —sin coste de calidad: ambos puntúan 2.4/3 en la rúbrica. Q3_K_M es algo más rápido (22.5 tok/s) y ligero (1.57 GB), pero su calidad cae a 2.0 porque empieza a fallar tareas exactas: en el problema aritmético calcula mal la duración del trayecto (235 en vez de 215 min). Esto justifica la elección de **Q4_K_M** como configuración de trabajo: es la rodilla de la curva, donde se gana toda la velocidad y memoria de cuantizar sin perder calidad. Frente a un hipotético Q5_K_M, Q4_K_M ya iguala la calidad de Q8 en nuestra rúbrica, así que el medio nivel extra de Q5 solo añadiría peso y RAM sin retorno medible. (Las tres fallan el acertijo de razonamiento transitivo, un límite del tamaño 3B que se discute en la Parte F, no de la cuantización.)

4.2 Parte B — KV cache

Contexto	Prompt real (tok)	Prefill (tok/s)	Gen (tok/s)	RAM pico (MB)	Latencia (s)
512	251	74.14	14.67	2080	22.38
2048	1535	75.83	14.15	2327	41.50
8192	6778	48.02	6.17	3079	174.08
16384	13840	35.69	4.01	3939	437.00




Figure 5: Contexto vs latencia y RAM

Tamaño teórico del KV cache de llama3.2 3B (28 capas, 8 KV-heads GQA, head dim 128, f16): $2 \cdot 28 \cdot 8 \cdot 128 \cdot 2 \text{ B} = 112 \text{ KB}$ por token $\rightarrow$ 57 MB a 512 tokens y 1.79 GB a 16 384. La medición lo confirma: la RAM pico sube de 2080 MB (512 tok) a 3939 MB (16 384 tok), un incremento de 1859 MB sobre 15 872 tokens adicionales = **117 KB/token**, a un 4 % del valor teórico de 112 KB/token. La latencia, en cambio, crece de forma **superlineal** (22 $\rightarrow$ 437 s, $\sim 20\times$): no es el KV cache sino el prefill, cuyo coste de atención es cuadrático en la longitud del contexto, lo que se ve también en el prefill cayendo de 74 a 36 tok/s. Es decir, la RAM escala con el KV cache (lineal) y la latencia con la atención del prompt (cuadrática). A 8K, el KV cache pesa $\sim 896 \text{ MB}$, lo que explica el salto de RAM de 2.3 a 3.1 GB respecto a 2K.

KV cache cuantizado (B.4). Repetimos la barrida con el KV cache en q8_0 (requiere flash attention). El ahorro de RAM **crece con el contexto**, como predice la teoría: a 512 tokens incluso cuesta 46 MB más (-2.2% , el KV cache es ínfimo y la flash attention añade overhead), pero a 2 048 ahorra 81 MB (3.5 %), a 8 192 ahorra 403 MB (13.1 %) y a 16 384 ahorra **784 MB (19.9 %)** de la RAM pico total. Esos 784 MB equivalen a $\sim 44 \%$ del KV cache f16 a 16K ($\sim 1.79 \text{ GB}$), cerca del 50 % teórico de pasar de 16 a 8 bits. El coste es de **latencia**: en CPU, cuantizar el KV cache encarece mucho el prefill (a 16K, de 437 s a 1051 s, $\sim 2.4\times$; prefill de 35.7 a 13.6 tok/s), porque la descuantización por token no se amortiza sin GPU. Conclusión práctica: en este hardware el KV-Q8 conviene solo cuando la RAM es el cuello de botella (contextos $\geq 8\text{K}$), no para acelerar.

4.3 Parte C — RAG

Pregunta (resumen)	Sin RAG (0-3)	Con RAG (0-3)
Variable que mueve el directorio de modelos (OLLAMA_MODELS)	0	3
Escuchar en todas las interfaces (OLLAMA_HOST=0.0.0.0)	1	2
Qué controla --n-gpu-layers en llama.cpp	0	3
Cuánto mantiene un modelo en memoria por defecto	0	1
Formato de pesos (GGUF) y para qué sirve el Modelfile	0	0
Media	0.2	1.8

El RAG multiplica por 9 la calidad factual media (0.2 $\rightarrow$ 1.8 sobre 3). Sin RAG, el modelo de 3B no “sabe” qué es Ollama y alucina sistemáticamente: inventa una variable OPENLMN_MODEL_DIR, un archivo ollama.conf inexistente y atribuye --n-gpu-layers a OpenCL. Con RAG acierta las preguntas cuya respuesta está literal en un único fragmento (OLLAMA_MODELS, --n-gpu-layers). Las dos

notas bajas con RAG son honestas y reveladoras: en “cuánto mantiene el modelo en memoria” recupera el contexto correcto pero responde “0 segundos” en vez de los 5 minutos reales (el modelo no lee bien el dato), y en la pregunta de GGUF/ Modelfile responde “no lo sé” pese a tener modelfile.md entre las fuentes recuperadas —un fallo de extracción, no de recuperación. Es decir, el cuello de botella ya no es encontrar el documento sino que un modelo de 3B lo lea con fidelidad.

4.4 Parte D — Herramientas vía MCP

Servidor MCP propio (SDK oficial de Python, transporte stdio) con 6 tools. Dos tareas end-to-end que requieren herramientas: (1) “Resume mis últimos 5 correos” → fetch_recent_emails → resumen hablado; (2) “Look up in the local docs which environment variable moves the Ollama model directory, then email the answer to test@example.com” → search_docs + send_email encadenadas. Fallos documentados con evidencia en FAILURES.md; resumen: funcionan de forma fiable los imperativos directos con la acción explícita (open_app “abre la calculadora”, web_search “busca en internet...”, fetch_recent_emails “resume mis últimos 5 correos”, search_docs “busca en los docs...”); fallan dos patrones concretos medidos en el test set. (a) **Tool call emitida como texto JSON**: en tool-02 (“open the website ollama.com”) el modelo escribió {"name":"open_website","parameters":{"url":...}} como texto en vez de invocar la herramienta, así que el sitio no se abrió (veredicto parcial). (b) **Multi-paso que se queda a medias o con argumentos vacíos**: en multi-01 (buscar en docs → enviar correo) encadenó las dos tools pero generó el send_email con body vacío; y multi-03 (buscar flash attention → abrir web) solo ejecutó search_docs y “olvidó” abrir la web. Además, las tools de correo (send_email, fetch_recent_emails) fallan en limpio porque el entorno de pruebas corre sin contraseña de aplicación de Gmail, lo que documentamos como límite de configuración, no de diseño.

4.5 Parte E — Evaluación

Categoría	n	Success	Partial	Fail	Éxito %	Latencia media (s)
chat	5	3	2	0	60 %	41.2
rag	4	3	1	0	75 %	22.8
tool	5	4	1	0	80 %	7.9
multi-step	3	2	1	0	67 %	20.8
adversarial	4	4	0	0	100 %	12.1
TOTAL	21	16	5	0	76 %	21.3

Tasa de éxito global del 76 % (16/21 success, 5 parciales, 0 fallos duros), 27 319 tokens consumidos en total. Lo mejor es la categoría **adversarial (100 %)**: Jarvis rechaza borrar archivos, no revela la contraseña ante una inyección de prompt, no inventa un Mundial de 2031 y no alucina una receta ausente del corpus. Lo más débil es **chat (60 %)**, por un motivo contraintuitivo y muy informativo: el modelo invoca search_docs **innecesariamente** en preguntas de chat puro (fotosíntesis, haiku, traducción), lo que dispara la latencia —el outlier de 126.7 s en chat-02 fue precisamente una llamada espuria a la herramienta que lanzó una excepción—. La latencia media por categoría refleja el coste de las tools y del prefill: las tareas que solo abren una app (tool, 7.9 s) son ~5× más rápidas que las que recuperan documentos (chat/rag). Nota de método: el veredicto cuenta la herramienta correcta y las palabras clave, no la corrección lógica fina; por eso chat-04 (razonamiento transitivo) aparece como “success” pese a dar mal el “segundo más alto” —el mismo fallo de 3B visto en la Parte A—, algo que se discute como limitación del evaluador en la Parte F.

5. Discusión (Parte F): límites honestos

Jarvis falla de formas concretas y reproducibles, todas presentes en el test set. **(1) Razonamiento multi-paso del propio modelo**. El acertijo de altura relativa (Anna/Berta/Carla/Diana) lo fallan las tres cuantizaciones en la Parte A y vuelve a fallar en chat-04: el modelo concluye que “no hay

segundo más alto” cuando la respuesta es Anna. Es un límite del tamaño 3B, no de la cuantización ni del RAG. **(2) Tool calling frágil.** En tool-02 la llamada sale como texto JSON en vez de invocar la herramienta, y en multi-01/multi-03 el encadenamiento de dos tools se queda a medias o con argumentos vacíos; sin el fallback `_tool_call_in_text` la tasa de tool calling caería bastante más. **(3) Sobre-uso de herramientas.** Preguntas de chat puro disparan `search_docs` sin necesidad (fotosíntesis, haiku), lo que provocó el pico de latencia de 126.7 s y una excepción en chat-02. **(4) Extracción factual imperfecta.** En el RAG, con el documento correcto recuperado, el modelo aún responde “0 segundos” donde la doc dice 5 minutos (rag-03), o “no lo sé” teniendo la fuente delante.

Cualitativamente, un LLM en la nube (probado informalmente con los mismos prompts) acierta el acertijo de razonamiento, no abusa de herramientas y extrae el dato de `keep_alive` sin error; su ventaja no está en “saber más” —el RAG iguala el acceso a hechos— sino en seguir instrucciones de varios pasos y leer el contexto con fidelidad. Nuestro Jarvis compensa parte de esa brecha con el RAG y un cliente de tools tolerante a fallos, pero no la cierra. Una limitación honesta adicional es del **evaluador**: cuenta tool correcta + keywords, no corrección lógica, por lo que sobreestima el éxito en chat (de ahí que chat-04 figure como success siendo incorrecto); con $n=21$ y un solo corrector, las cifras son indicativas, no concluyentes.

Mejoras factibles con 2× RAM o una GPU pequeña. (1) Con 32 GB de RAM cabría un modelo 8B en Q5_K_M con contexto de 32K (pesos ~5.7 GB + KV ~3.6 GB), que en nuestra experiencia cualitativa elimina la mayor parte de los fallos de tool calling multi-paso; el coste es ~2× menos tokens/s en CPU. (2) Con una GPU de 8 GB (la RTX 4060 que este equipo tiene deshabilitada) las mismas 28 capas del 3B caben enteras en VRAM: el prefill pasaría de decenas a miles de tokens/s, haciendo viable el RAG con top-K mayor ($K=10$) y contextos largos sin la penalización de latencia medida en la Parte B.

6. Apéndice de reproducibilidad

```
git clone <REPO_URL> && cd IRONMAN
.\setup.ps1                                # venv + deps + modelos + índice RAG
python benchmarks\parte_a_cuantizacion.py  # Parte A -> measurements.csv
python benchmarks\parte_b_kvcache.py      # Parte B (KV f16)
.\benchmarks\run_kv_quant.ps1             # Parte B.4 (KV q8_0)
python benchmarks\graficas.py             # gráficas
python rag\parte_c_rag.py compare          # Parte C
python evaluacion\parte_e_evaluacion.py    # Parte E
python asistente\jarvis.py                 # demo interactiva (texto)
```

Versiones: Ollama 0.30.6, Python 3.13, paquetes fijados en `requirements.txt` (ollama 0.6.2, mcp 1.27.2, sqlite-vec 0.1.9, psutil 7.2.2). Semillas: `temperature=0`, `seed=42` en todos los experimentos.

7. Referencias

[1] Ollama. “Ollama documentation.” docs.ollama.com, 2026. [2] G. Gerganov et al. “llama.cpp: LLM inference in C/C++.” github.com/ggml-org/llama.cpp, 2026. [3] Meta AI. “Llama 3.2: Revolutionizing edge AI and vision with open models.” 2024. [4] Z. Nussbaum et al. “Nomic Embed: Training a Reproducible Long Context Text Embedder.” arXiv:2402.01613, 2024. [5] Anthropic. “Model Context Protocol.” modelcontextprotocol.io, 2024. [6] A. Garcia, sqlite-vec: “A vector search SQLite extension.” github.com/asg017/sqlite-vec, 2024. [7] T. Dettmers, L. Zettlemoyer. “The case for 4-bit precision: k-bit Inference Scaling Laws.” ICML, 2023. [8] R. Pope et al. “Efficiently Scaling Transformer Inference.” MLSys, 2023.

AI Use Statement

Este proyecto usó **Claude (Anthropic)** como asistente de programación para: estructurar el repositorio, escribir la primera versión de los scripts de benchmark, del servidor/cliente MCP, del pipeline RAG y del runner de evaluación, y redactar el borrador de este reporte. Todas las mediciones se ejecutaron en el hardware descrito y fueron revisadas por el autor, que entiende y puede defender cada número. El LLM evaluado (llama3.2 3B local) NO se usó para escribir código ni prosa del reporte; los LLMs en la nube no participan en ningún camino de inferencia del sistema.